

SEMESTERPROJEKT

Wo entsteht Sentiment in Large Language Models?

Eine mechanistische Interpretierbarkeit der Sentimentverarbeitung von Pythia-410M

Präsentiert von:

Islam Abdalla

Alireza Roozitalab

Daniel Durst-Claus

Agenda

01 Grundlagen

02 Hypothese 1

Eindeutig polare Wörter wie „wonderful“ oder „delicious“ werden früh und direkt am Token verarbeitet

03 Hypothese 2

Das Modell erkennt keine Ironie, sondern verarbeitet ausschließlich die wörtliche Oberflächen-Polarität

04 Hypothese 3

Die kausal verantwortliche Verarbeitung lässt sich auf eine bestimmte Schicht und Token-Position eingrenzen, statt über das gesamte Netz verteilt zu sein

05 Fazit

Phänomen: Sentiment Analyse

DEFINITION

Sentiment Analyse bewertet automatisch, **ob eine Aussage positiv oder negativ** ist.
Mechanistische Interpretierbarkeit untersucht dabei, **wie das Modell intern zu dieser Einschätzung kommt.**

BEISPIEL - Decoder-Only-Modell

„The movie was really
good and everyone ...



loved

„The movie was really
bad and everyone ...



hated

Pythia-410M (EleutherAI)

405 M.

Parameter

24

Schichten

je 16



Attention-Heads

1 024

Hidden-Size


50 304

Vokabular



Verwendete Datensätze | Hu Liu Dataset – Überblick und Verwendung

Hu & Liu Opinion Lexicon → Filterung auf Ein-Token-Wörter



Verwendete Datensätze | Sentiment Challenge Dataset – Überblick und Verwendung

(Mohammad, Kiritchenko, Zhu, Cherry, Saif, Vajjala & Ruder, 2017)

Was ist das Sentiment Challenge Dataset?



Ein Benchmark-Datensatz für Sentimentanalyse, veröffentlicht im Rahmen der SemEval-2017 Task 4.



Erstellt und zusammengestellt von **verschiedenen Forschungsgruppen**.



Enthält kurze Texte aus unterschiedlichen Quellen (Tweets, Produktreviews, Fragmente aus Foren, Nachrichten, etc.).



Drei Klassen: **positiv**, **negativ**, neutral.



Originaler Datensatz (SCD)

- **11.855 positiv**
- **11.924 negativ**
- **9.838 neutral**

Insgesamt 33.617 Beispiele

Aufbau des Datensatzes

Klasse	Anzahl Beispiele
 Positiv	11.855
 Negativ	11.924
 Neutral	9.838

Insgesamt 33.617 Beispiele

Weiterführende Kategorisierung durch Täckström et al. (2019)

Eine andere Gruppe annotierte einen Teilmenge des SCD und kategorisierte die Beispiele in feingranulare Phänomene.

Diese Kategorien helfen zu verstehen, warum Beispiele schwierig zu klassifizieren sind.

Kategorie	Anzahl	Kategorie	Anzahl
Incorrect label	277	Amplifier	79
No sentiment	214	Comparative	68
Mixed	185	Sarcasm/Irony	58
Non-standard spelling	180	Shifter	50
Desirable element	144	Emoji	46
Idioms	132	Modality	38
Strong	122	Morphology	31
Negation	97	Reducer	13
World knowledge	81		

Beispiele (aus dem SCD)

"I love this movie. It was absolutely wonderful!"
(positiv)

"The battery life is terrible and the screen is awful."
(negativ)

"It's an average phone. Nothing special."
(neutral)

Verwendung in dieser Arbeit



Bewertung der Sentiment-Vorhersagen von Pythia-410M auf einem standardisierten, vielfältigen Benchmark.



Analyse der Modellperformance für die verschiedenen Kategorien.



Untersuchung, wie Sentiment-Informationen im Modell repräsentiert und über die Schichten verarbeitet werden.



Vergleich der Ergebnisse mit anderen Methoden (z. B. Logit Lens, Linear Probing, Activation Patching).




Im Projekt verwendet:
Neutrale Beispiele wurden gefiltert und nicht verwendet.

→ Verwendet: **283 positiv + 353 negativ**
= 636 Beispiele


Semesterprojekt | AI Frameworks & Tools | Hochschule Aalen

Verwendete Datensätze | Sentiment Challenge Dataset – Überblick und Verwendung



Verwendete Datensätze | Counterfactually Augmented Dataset (CAD) – Überblick und Verwendung

(Kaushik et al., 2020)



Vergleich der verwendeten Datensätze

	Hu & Liu Opinion Lexicon (Hu & Liu, 2004)	Sentiment Challenge Dataset (SCD) (SemEval-2017 Task 4)	Counterfactually Augmented Dataset (CAD) (Kaushik et al., 2020)
 Quelle / Ursprung	Hu & Liu, 2004	SemEval-2017 Task 4; zusätzliche Kategorisierung durch spätere Arbeit (2019)	Kaushik et al., 2020
 Inhalt	Listen positiver und negativer Wörter (Ein-Token-Wörter)	Schwierige Sentiment-Beispiele aus verschiedenen Phänomenen (z. B. Negation, Ironie, Idiome, Mixed Sentiment, Emoji usw.)	Paare aus Original-Prompt und kontrafaktischem Prompt mit entgegengesetztem Sentiment, bei gleichem Inhalt
 Größe in diesem Projekt	 865 positive Wörter  1.389 negative Wörter Insgesamt 2.254 Ein-Token-Wörter	 283 positive Beispiele  353 negative Beispiele Insgesamt 636 Beispiele (neutrale Beispiele gefiltert)	 1.707 positive/negative Prompt-Paare (1 Original + 1 kontrafaktischer Prompt)
 Gelabelt?	✓ Ja (Positiv / Negativ)	✓ Ja (Positiv / Negativ / Neutral)	✓ Ja (Positiv / Negativ)
 Kategorisiert?	✗ Nein	✓ Ja (Negation, Ironie, Idiome, Emoji, Mixed, usw.)	✗ Nein
 Paarweise Beispiele?	✗ Nein	✗ Nein	✓ Ja
 Gleicher Inhalt, anderes Sentiment?	✗ Nein	✗ Nein	✓ Ja
 Ebene (Granularität)	Wortebene (Ein-Token)	Satzebene	Satzebene
 Hauptnutzen in dieser Arbeit	• Basislexikon für Sentiment-Analysen • Berechnung von Sentiment-Scores über Logits (Logit Lens) • Auswahl positiver/negativer Ein-Token-Wörter für Embedding-Analysen	• Untersuchung der Modelleistung über verschiedene Sentiment-Phänomene • Analyse, wie gut Modelle mit komplexen und nicht-wörtlichen Sentimenten umgehen	• Isolierte Analyse des Effekts von Sentiment, indem der Inhalt konstant gehalten wird • Paarweise Analyse von Repräsentationen (Logit Lens, Linear Probing, Attention, Activation Patching usw.)
 Besonderheiten	Lexikonartige Ressource mit breiter Abdeckung von Ein-Token-Wörtern	Manuell kategorisierte Beispiele (2019) für feinere Analysen	Kontrafaktische Methode stellt sicher, dass nur das Sentiment, nicht der Inhalt, verändert wird



Zusammengefasst:

Die drei Datensätze ergänzen sich ideal: Das Lexikon liefert die Grundbausteine, SCD deckt komplexe Sentiment-Phänomene ab, und CAD ermöglicht kontrollierte Analysen des Sentimenteffekts bei unverändertem Inhalt.

HYPOTHESE 1

Embedded Space Analyse & H1

Hypothese 1 (Klare Stimmungswörter)

Eindeutig polare Wörter wie „wonderful“ oder „delicious“ werden früh und direkt am Token verarbeitet.

Embedded Space Analyse & H1 | Überblick - Visualisierung

Überblick - Visualisierung



1. Dataset

Hu & Liu Opinion Lexicon
2245 Ein-Token-Wörter



2. Embedding

Für jedes Wort -> Token
1024-dimensional Vektor





3. Visualisierung

1024 Dimensionen?
Mit PCA auf 2 reduzieren

HYPOTHESE 1

Embedded Space Analyse & H1 | Überblick - Visualisierung



Embedded Space Analyse & H1 | Überblick - Linear Probing



1. Dataset

Hu & Liu Opinion Lexicon
2245 Ein-Token-Wörter



2. Embedding

Für jedes Wort -> Token
1024-dimensional Vektor




3. Linear Probing

Logistic Regression Modell
Positiv & negativ
klassifizieren

HYPOTHESE 1

Embedded Space Analyse & H1 | Überblick - Linear Probing

- Accuracy = 0,9690
- Precision = 0,9760
- Recall = 0,9422
- F1 score = 0,9588



Embedded Space Analyse & H1 | Überblick - Embedded Space Arithmetik



1. Dataset

Hu & Liu Opinion Lexicon
2245 Ein-Token-Wörter



2. Embedding

Für jedes Wort -> Token
1024-dimensional Vektor



3. Embedded Arithmetik

„excellent“ – „bad“ = ?


Embedded Space Analyse & H1 | Überblick – Embedded Space Arithmetik

- In dem Embedded Space ein Token ist als 1024-dimensional Vector repräsentiert
- Experiment: „king“ – „man“ + „woman“ = ?



Embedding arithmetic: king - man + woman		

' king'	token_id= 6963	similarity=+0.6772
' King'	token_id= 4377	similarity=+0.4597
' queen'	token_id= 19538	similarity=+0.4550
' woman'	token_id= 3416	similarity=+0.4448
' King'	token_id= 21958	similarity=+0.4235



Embedded Space Analyse & H1 | Embedded Arithmetik

- In dem Embedded Space ein Token ist als 1024-dimensional Vector repräsentiert
- Experiment: „king“ – „man“ + „woman“ = „queen“
- Vielleicht geht Sentiment auch?

Embedding arithmetic: happy - sad

'happy'	token_id= 5211	similarity=+0.5929	HuLiu:positive: happy
'happy'	token_id= 42256	similarity=+0.4100	HuLiu:positive: happy
'Happy'	token_id= 27575	similarity=+0.3142	HuLiu:positive: happy
'Happy'	token_id= 33298	similarity=+0.2951	HuLiu:positive: happy
'happily'	token_id= 26174	similarity=+0.2338	HuLiu:positive: happily

Embedding arithmetic: good + excellent - bad

'excellent'	token_id= 7126	similarity=+0.7673	HuLiu:positive: excellent
'good'	token_id= 1175	similarity=+0.6207	HuLiu:positive: good
'Excellent'	token_id= 48438	similarity=+0.4961	HuLiu:positive: excellent
'cellent'	token_id= 26128	similarity=+0.4911	
'Excellent'	token_id= 45441	similarity=+0.4538	HuLiu:positive: excellent

Embedding arithmetic: terrible + sad - great

'sad'	token_id= 8872	similarity=+0.6892	HuLiu:negative: sad
'terrible'	token_id= 11527	similarity=+0.5581	HuLiu:negative: terrible
'Sad'	token_id= 41052	similarity=+0.3597	HuLiu:negative: sad
'horrible'	token_id= 19201	similarity=+0.3532	HuLiu:negative: horrible
'Sad'	token_id= 21995	similarity=+0.3428	HuLiu:negative: sad

Embedding arithmetic: excellent - good

'excellent'	token_id= 7126	similarity=+0.5480	HuLiu:positive: excellent
'cellent'	token_id= 26128	similarity=+0.3015	
'Excellent'	token_id= 48438	similarity=+0.2946	HuLiu:positive: excellent
'Excellent'	token_id= 45441	similarity=+0.2869	HuLiu:positive: excellent
'extremely'	token_id= 6685	similarity=+0.2308	

Embedding arithmetic: terrible - bad

'terrible'	token_id= 11527	similarity=+0.5550	HuLiu:negative: terrible
'dreadful'	token_id= 38074	similarity=+0.3409	HuLiu:negative: dreadful
'horrible'	token_id= 19201	similarity=+0.3229	HuLiu:negative: horrible
'tremendous'	token_id= 19999	similarity=+0.2816	
'awful'	token_id= 18580	similarity=+0.2769	HuLiu:negative: awful

Embedded Space Analyse & H1

Hypothese 1 (Klare Stimmungswörter)

- Eindeutig polare Wörter wie „wonderful“ oder „delicious“ werden **früh und direkt am Token verarbeitet**. Bestätigt, wenn die Polarität bereits in frühen bis mittleren Schichten ablesbar ist und ein Eingriff am Stimmungswort die Vorhersage wiederherstellt.
- Lässt sich mit unserer bisherige Analyse **bestätigen**
 - Sentiment positive und negative Wörter sind nach dem Embedding Matrix
 - linear trennbar
 - Mit Nachbar Analyse und Embedded Arithmetik nicht zufällig verteilt

Prädiktion Analyse & H2

Hypothese 2 (Ironie und Sarkasmus)

Das Modell erkennt keine Ironie, sondern verarbeitet nur die wörtliche Oberflächen-Polarität.

Beispiele aus dem SCD-Dataset, Kategorie (*sarcasm/irony*):

- “*Better at putting you to sleep than a sound machine .*” (label: **negative**)
- “*It 's difficult to say whether The Tuxedo is more boring or embarrassing -- I 'm prepared to call it a draw .*” (label: **negative**)

Prädiktion Analyse & H2 - Überblick



1. Dataset

SCD Dataset
636 labeled Prompts
verschiedene Kategorien
+ suffix „I feel very“



2. Inference

Für jedes Wort -> Token
1024-dimensional Vektor



3. Visualisierung


$P_p(\text{nächste Token})$
 $P_n(\text{nächste Token})$
Analyse



4. Dataset

Hu & Liu Opinion Lexicon
2245 Ein-Token-Wörter

Prädiktion Analyse & H2 - Visulisierung



Prädiktion Analyse & H2


Hypothese 2 (Ironie und Sarkasmus)

- **H2: Das Modell erkennt keine Ironie, sondern verarbeitet nur die wörtliche Oberflächen-Polarität.**
- Lässt sich mit unserer bisherige Analyse teilweise bestätigen, bleibt die Evidenz jedoch eingeschränkt.

Die kausal verantwortliche Verarbeitung lässt sich auf eine bestimmte Schicht und Token-Position eingrenzen, statt über das gesamte Netz verteilt zu sein



VORGEHEN

- 1 Prompt-Paar „delicious“/„disgusting“ & sauberer vs. korumpierter Lauf (Logit Lens)
- 2 Lokalisierbarkeit durch Linear-Probing-Analyse
- 3 Identifikation sentimentrelevanter Attention Heads(Attention-Head-Analyse)
- 4 Aktivierung je Schicht × Position ersetzen (Activation-Patching-Analyse)



HYPOTHESE 3


Lokalisierbarkeit durch Logit-Lens-Analyse :



ERKENNTNISSE

- Beginn der Trennung : Schicht 5
- Signifikanter Anstieg ab Schicht 17
- Die größte Veränderung erfolgt in der letzten Schicht 24

Lokalisierbarkeit durch Logit-Lens-Analyse :




ERKENNTNISSE

- Erste positive Signale ab Schicht 11
- Deutliche Trennung ab Schicht 17
- Klare positive Vorhersagen erst inder letzten Schicht

HYPOTHESE 3


Lokalisierbarkeit durch Logit-Lens-Analyse (CAD Dataset) :



ERKENNTNISSE

- Beginn der Änderung : Schicht 4
- Signifikanter Anstieg ab Schicht 17
- Die größte Veränderung erfolgt in der letzten Schicht 24


Lokalisierbarkeit durch Linear-Probing-Analyse (CAD Dataset) :



ERKENNTNISSE

- Mit einer Genauigkeit von etwa 67 % enthält Schicht 17 die am besten auslesbare Sentimentinformation
- Die Sentimentinformation ist bereits ab Schicht 6-7 über Zufallsniveau (50 %) klassifizierbar.

Lokalisierbarkeit durch Attention-Head-Analyse :




ERKENNTNISSE

Starke Fokussierung einzelner Heads auf Sentimentwörter

Stärkste Attention Heads in frühen Schichten (Layer 0–10)

Maximum: Layer 6, Head 3 (Attention = 0,835)

Lokalisierbarkeit durch Attention-Head-Analyse (CAD Dataset) :



ERKENNTNISSE

Starke Fokussierung einzelner Heads auf Sentimentwörter

Stärkste Attention Heads in frühen Schichten (Layer 0–10)


Maximum: Layer 5, Head 3 (Attention = 0,019)

HYPOTHESE 3

Lokalisierbarkeit durch Activation-Patching-Analyse :

Prompt: food was delicious/disgusting and I felt very

Zielwort : „satisfied “



ERKENNTNISSE

- Stärkster kausaler Einfluss: Token „disgusting“
- Sentimentinformation entsteht bereits in frühen Schichten
- Die Information wird bis in die späten Schichten weitergegeben

HYPOTHESE 3

Die kausal verantwortliche Verarbeitung lässt sich auf eine bestimmte Schicht und Token-Position eingrenzen, statt über das gesamte Netz verteilt zu sein

VORGEHEN

- 1 Prompt-Paar „delicious“/„disgusting“ & sauberer vs. korumpierter Lauf (Logit Lens)
- 2 Lokalisierbarkeit durch Linear-Probing-Analyse
- 3 Identifikation sentimentrelevanter Attention Heads(Attention-Head-Analyse)
- 4 Aktivierung je Schicht × Position ersetzen (Activation-Patching-Analyse)

ERGEBNIS


Alle vier Analysen zeigen, dass Sentimentinformationen bestimmten Schichten und Modellkomponenten zugeordnet werden können. Die Ergebnisse sprechen daher für eine Lokalisierbarkeit der Sentimentrepräsentation und unterstützen Hypothese H3(Lokalisierbarkeit).

FAZIT

- Sentiment ist bereits im **Embedding-Raum** von Pythia-410M strukturiert und für Ein-Token-Wörter linear trennbar.
- **Logit-Lens**-Analysen zeigen, dass sich stärkste Sentiment-Separation in den **letzten Schichten** (ca. Layer 17–23) entsteht und ihr Maximum kurz vor der Ausgabe erreicht.
- **Linear Probing** auf dem CAD-Datensatz bestätigt, dass Sentimentinformationen bereits in frühen Schichten vorhanden sind und mit zunehmender Tiefe immer besser lesbar werden.
- **Attention-Analysen** zeigen, dass einzelne Köpfe sentimenttragende Wörter berücksichtigen, die Aufmerksamkeit jedoch über viele Köpfe und Schichten verteilt ist.
- **Activation Patching** identifiziert das sentimenttragende Wort in den **ersten Schichten** als kausal relevante Informationsquelle.
- **Korrelation und Kausalität nicht notwendigerweise an denselben Modellkomponenten auftreten.**

FAZIT

Was ist in der Black Box?!



FAZIT

Was ist in der Black Box?!

